Informe final - Proyecto Adult Income ML

Autor: Andrés Felipe Villanueva Parra **Rama de trabajo:** `dev_anvillanueva43` **Fecha:** 2026-11-03

1. Problema y datos

El objetivo académico es clasificar si una fila del dataset Adult corresponde a un ingreso anual superior a 50.000 USD (`>50K`). La fuente es el UCI Machine Learning Repository, Adult (ID 2), basado en datos del Censo de Estados Unidos de 1994.

El dataset consolidado tiene **48.842 registros**. La clase positiva contiene 11.687 filas (23,9%) y la clase `<=50K` 37.155 (76,1%). Se excluye `fnlwgt` del modelo porque es un peso censal. Se usan 13 predictores: cinco numéricos (`age`, `education-num`, `capital-gain`, `capital-loss`, `hours-per-week`) y ocho categóricos (`workclass`, `education`, `marital-status`, `occupation`, `relationship`, `race`, `sex`, `native-country`).

2. Preparación y separación

El conjunto se divide en **39.073 filas de train** y **9.769 de test**, con estratificación por etiqueta y `random_state=42`. El conjunto de test se usa una vez al final de cada flujo de modelado.

Tipo	Transformación	Faltantes y ajuste
Numérico	`SimpleImputer(strategy="median")` y `StandardScaler`	Medianas y escala se aprenden solo de train.
Categórico	`SimpleImputer(strategy="most_frequent")` y `OneHotEncoder(handle_unknown="ignore")`	Moda y categorías se aprenden solo de train; las categorías no vistas no fallan en test.

La fuente presenta valores desconocidos en `workclass`, `occupation` y `native-country`, que el cargador normaliza como faltantes. El preprocesamiento está dentro de un `Pipeline` de scikit-learn para evitar fuga de información.

3. Modelos

- **Regresión Logística:** modelo principal, `class_weight="balanced"`, `max_iter=1000`, semilla 42.

- **DummyClassifier:** baseline `most_frequent`, predice la clase más frecuente.

- **Árbol de Decisión:** comparación con `max_depth=5` y `class_weight="balanced"`.

4. Resultados en el test

Los siguientes valores se generaron al ejecutar el Notebook 02 con Python 3.12.14, pandas 3.1.0 y scikit-learn 1.9.1. Las métricas están redondeadas a cuatro decimales.

Modelo	Accuracy	Precision	Recall	F1-score
Regresión Logística	0.8056	0.5632	0.8370	0.6733
Árbol de Decisión	0.7806	0.5248	0.8824	0.6582
DummyClassifier	0.7607	0.0000	0.0000	0.0000

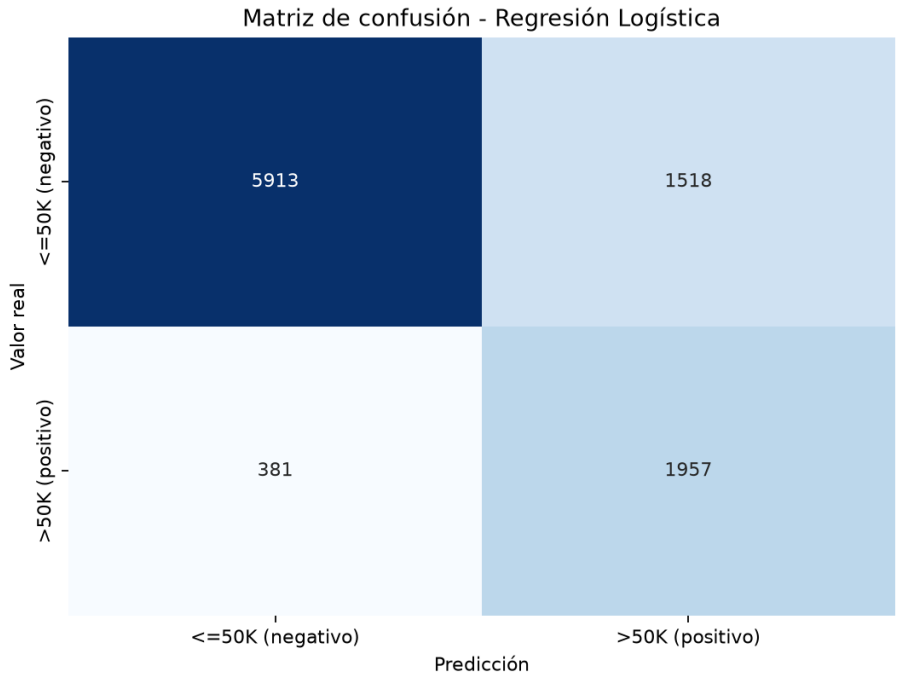
La regresión logística mejora todas las métricas frente al Dummy. El Árbol obtiene mayor recall, pero menor accuracy, precision y F1 que la regresión logística. En este problema precision y recall describen compromisos distintos: el recall mide cuántos ingresos `>50K` se detectan; precision indica cuántas predicciones `>50K` son correctas.

4.1 Matriz de confusión de Regresión Logística

Etiqueta real	Predicho <=50K	Predicho >50K
Real <=50K	5.913 (VN)	1.518 (FP)
Real >50K	381 (FN)	1.957 (VP)

- **Verdaderos positivos (VP):** 1.957 filas con ingresos reales `>50K` clasificadas como positivas.
- **Verdaderos negativos (VN):** 5.913 filas `<=50K` clasificadas como negativas.
- **Falsos positivos (FP):** 1.518 filas `<=50K` clasificadas como `>50K`.
- **Falsos negativos (FN):** 381 filas `>50K` clasificadas como `<=50K`.

Matriz de confusión de la Regresión Logística



4.2 Criterios de aceptación académica

Criterio	Umbral	Resultado	Estado
Accuracy	>0.75	0.8056	Cumple
F1-score	>0.60	0.6733	Cumple
Recall de >50K	>0.55	0.8370	Cumple
Mejora sobre Dummy	Las cuatro métricas	Sí	Cumple

Estos umbrales se definieron para verificar el ejercicio de curso; no son una norma de calidad para un modelo desplegado ni un aval para usarlo con personas.

5. Análisis ético por grupos

Se reentrena la regresión logística con la misma división para medir recall, precision, F1 y tasas de positivos reales y predichas por grupo. Los valores son descriptivos del conjunto test y dependen de la etiqueta histórica de la fuente.

5.1 Sexo

Grupo	N	Tasa real >50K	Tasa predicha >50K	Recall	Precision	F1
Female	3.289	0.1116	0.1396	0.6839	0.5468	0.6077
Male	6.480	0.3042	0.4654	0.8656	0.5656	0.6842

Brecha max-min de recall: **0.1817**. Brecha max-min de tasa positiva predicha: **0.3258**.

5.2 Raza

Grupo	N	Tasa real >50K	Tasa predicha >50K	Recall	Precision	F1
Amer-Indian-Eskimo	104	0.0865	0.2019	0.6667	0.2857	0.4000
Asian-Pac-Islander	304	0.2566	0.4046	0.8462	0.5366	0.6567
Black	944	0.1282	0.1515	0.6529	0.5524	0.5985
Other	69	0.1594	0.1884	0.6364	0.5385	0.5833
White	8.348	0.2538	0.3803	0.8490	0.5666	0.6796

Brecha max-min de recall: **0.2126**. Brecha max-min de tasa positiva predicha: **0.2531**. El grupo `Other` incluye 69 filas de test; las tasas de grupos pequeños son menos estables.

5.3 Rango de edad

Rango	N	Tasa real >50K	Tasa predicha >50K	Recall	Precision	F1
18-29	2.945	0.0499	0.0954	0.7143	0.3737	0.4907
30-39	2.517	0.2706	0.3747	0.7959	0.5748	0.6675
40-49	2.124	0.3719	0.5061	0.8620	0.6335	0.7303
50-59	1.382	0.3734	0.5499	0.8527	0.5789	0.6897
60+	801	0.2547	0.5194	0.9265	0.4543	0.6097

Brecha max-min de recall: **0.2122**. Brecha max-min de tasa positiva predicha: **0.4545**.

Las brechas indican diferencias observadas en este test y bajo este umbral; no son por sí solas una prueba estadística de discriminación ni una definición completa de justicia. La tasa base real varía por grupo, y distintos criterios de equidad pueden entrar en tensión.

6. Sesgos, privacidad e impacto social

1. **Sesgo histórico y temporal:** las etiquetas reflejan condiciones económicas y sociales de Estados Unidos en 1994; no describen ingresos presentes ni otras poblaciones.

2. **Representación desigual:** los tamaños de grupo son diferentes; un valor agregado puede ocultar errores concentrados y los grupos pequeños presentan mayor incertidumbre.

3. **Variables proxy:** educación, ocupación, estado civil y otras variables pueden codificar desigualdades vinculadas a atributos sensibles.

4. **Equidad:** se observan diferencias en recall y tasas positivas predichas por sexo, raza y edad. Igualdad de oportunidad y paridad demográfica no se satisfacen simultáneamente en estas tablas.

5. **Privacidad:** el dataset es público y no contiene nombres en este análisis, pero combina atributos sensibles. Se conservan métricas agregadas, se excluyen perfiles individuales del repositorio y no se intenta reidentificar registros.

6. **Transparencia y justicia:** la predicción no explica causas ni sustituye una valoración individual. Una eventual aplicación necesitaría validación actual, análisis de impacto, revisión humana, explicación entendible y mecanismo de reclamación.

El impacto de automatizar decisiones laborales o económicas con este modelo podría amplificar desigualdades y restringir oportunidades. Por ello, el sistema se limita explícitamente a docencia y no debe usarse para contratación, crédito, seguros, salarios u otros contextos de alto impacto.

7. Conclusiones y recomendaciones

- La regresión logística supera al baseline con accuracy 0.8056 y F1 0.6733; detecta 83.70% de los positivos en el test.

- Los tres criterios de umbral y la comparación con baseline se cumplen en la partición definida.

- Hay diferencias descriptivas relevantes entre grupos; el resultado no permite inferir equidad o desempeño fuera de este dataset histórico.

- Para continuar el trabajo: validar con datos actuales y representativos, reportar incertidumbre por grupo, evaluar más de una partición, justificar las variables y realizar una revisión independiente de impacto y privacidad.

- Mantener el uso como ejercicio académico sin despliegue ni decisiones automatizadas sobre personas.

8. Archivos y reproducción

Archivo	Propósito
`data/descargar_datos.py`	Descarga reproducible desde UCI.
`notebooks/01_exploracion.ipynb`	Exploración de datos y faltantes.
`notebooks/02_modelo_y_metricas.ipynb`	Entrenamiento, métricas y matrices de confusión.
`notebooks/03_analisis_etico.ipynb`	Métricas por sexo, raza y edad.
`data/tabla_metricas.csv`	Comparación de modelos reproducida.
`data/metricas_por_*.csv`	Tablas de evaluación por grupo.
`data/confusion_lr.png`	Matriz de confusión de Regresión Logística.

Desde la raíz del repositorio, instala las dependencias con `python -m pip install -r requirements.txt`, descarga Adult con `python data/descargar_datos.py` y ejecuta los notebooks en el orden 01, 02, 03. Los comandos completos están en el README. La copia fuente `data/adult_income.csv` no se versiona.

Referencias

- Dua, D. y Graff, C. *UCI Machine Learning Repository: Adult*. https://archive.ics.uci.edu/dataset/2/adult

- Pedregosa, F. et al. *Scikit-learn: Machine Learning in Python*. https://scikit-learn.org/

- Proyecto implementado con Python, pandas, scikit-learn, matplotlib, seaborn y Jupyter; versiones instaladas durante esta ejecución declaradas en la salida del entorno local.